

文章编号: 1009 - 444X(2025)04 - 0382 - 07

基于机器学习的汽车阻力系数预测研究

张红伟¹, 袁子厚^{1,2}, 杜焱铭¹, 郑兴任¹

(1. 武汉纺织大学 机械工程与自动化学院, 湖北 武汉 430200; 2. 湖北省数字化纺织装备重点实验室, 湖北 武汉 430200)

摘要: 扩散器是一种先进的空气动力学改进装置, 通过有效引导气流来降低车辆的阻力系数。为降低汽车空气动力学性能开发的时间成本, 将其安装在 Ahmed 模型侧面, 扩散器的特征尺寸作为设计变量, 阻力系数为响应值。采用最优拉丁超立方实验设计 (DOE) 方法生成 DOE 矩阵。再运用 Fluent 求解每组实验方案的阻力系数仿真值。构建数据集后, 应用于径向基函数 (RBF)、极端随机树 (Extra Trees)、极限梯度提升树 (XGBoost)、粒子群优化-反向传播 (PSO-BP) 等模型, 结果表明 PSO-BP 模型预测精度最佳, RBF 模型最差。通过 Extra Trees 算法分析 5 个设计变量对阻力系数的影响程度, 影响最大的变量为 X_1 , 影响最小的变量为 X_5 , 由此可得机器学习应用于汽车空气动力学设计的可行性。

关键词: 机器学习; 极端随机树; 极限梯度提升; 粒子群优化-反向传播混合算法; 阻力系数

中图分类号: O357.5 + 2

文献标志码: A

Research on prediction of vehicle drag coefficient based on machine learning

ZHANG Hongwei¹, YUAN Zihou^{1,2}, DU Yanming¹, ZHENG Xingren¹

(1. School of Mechanical Engineering and Automation, Wuhan Textile University, Wuhan 430200, China;

2. Hubei Digital Textile Equipment Key Laboratory, Wuhan 430200, China)

Abstract: A diffuser is an advanced aerodynamic improvement device that reduces the drag coefficient of a vehicle by efficiently guiding airflow. To reduce the time required for developing vehicle aerodynamic performance, it was mounted on the sides of the Ahmed model, with the characteristic dimensions of the diffuser serving as design variables and the drag coefficient as the response. The optimal Latin hypercube experimental design method was employed to generate the design of experiments (DOE) matrix. Subsequently, Fluent was used to solve the simulated drag coefficients for each experimental scenario. After the dataset was constructed, it was applied to several machine learning models, including radial basis function (RBF), Extra Trees, extreme gradient boosting (XGBoost), and particle swarm optimization-backpropagation (PSO-BP). The results demonstrated that the PSO-BP model achieved the best prediction accuracy, whereas the RBF model performed the worst. Finally, the Extra Trees algorithm was used to analyze the influence of five design variables on the drag coefficient. The X_1 exerted the highest influence, while X_5 had the least. This demonstrates that the application of machine learning to automobile aerodynamic design is feasible.

Key words: machine learning; Extra Trees; extreme gradient boosting (XGBoost); particle swarm

收稿日期: 2024 - 06 - 26

基金项目: 国家自然科学基金 (11502177); 湖北省数字化纺织装备重点实验室开放基金项目 (DTL2019019)

作者简介: 张红伟 (1999 -), 男, 硕士, 研究方向为汽车流体仿真。E-mail: 13636032104@163.com

通信作者: 袁子厚 (1966 -), 男, 教授, 博士, 研究方向为汽车碰撞分析与流体仿真。E-mail: whuyzh@163.com

optimization-back propagation (PSO-BP) algorithm; drag coefficient

机器学习技术的蓬勃发展,使各国学者开始探索神经网络等模型用于空气阻力系数的精准预测。这不仅表明机器学习在科学研究领域得到广泛应用,也预示在提升汽车气动性能方面新的可能性和机遇。Rostamzadeh-renani等^[1]在二维的Ahmed汽车模型顶部设计襟翼,对比不同回归预测模型,采用GMDH神经网络预测,并结合灰狼等优化算法求得最优解,汽车阻力系数和升力系数分别降低21.27%和19.91%。Gunpinar等^[2]通过主成分分析提取二维汽车轮廓特征,采用神经网络建立模型对空气阻力系数进行预测。Andrés-pérez等^[3]比较SVR、Decision tree、Lasso、MLP等模型对NACA0012翼型、RAE2822翼型和3D DPW机翼的空气阻力系数的预测结果,得到深度学习方法应用于空气动力学分析和设计中具有可行性和高效性。姜丰等^[4]将遗传算法与BP神经网络结合,对权重和阈值进行优化以减小误差,提高预测精度,进而提出一种高精度的GA-BP神经网络预测模型对MIRA汽车模型的阻力系数进行预测。

综上所述,在汽车空气动力学领域,结合机器学习进行优化设计并不多见,仍然有很大的探索空间。本研究将汽车尾部扩散器安装到Ahmed汽车模型后保险杠的侧面,将扩散器的特征尺寸作为设计变量,阻力系数(C_D)作为目标函数,结合实验设计方法设计40组样本数据,应用于不同预测模型,比较其预测精度。

1 数值模拟模型的建立

1.1 Ahmed汽车模型

以Ahmed汽车模型为研究对象,并在原始模型尾部后保险杠的侧面上安装扩散器,该基准模型的基本特征参数包括:车长(L)为1 044 mm,车宽(W)为389 mm,最大高度(H)为338 mm,细节尺寸和安装扩散器后的汽车模型如图1所示。

1.2 设计计算域和划分网格

在仿真过程中,为了最小化风洞壁面对计算结果的影响,本研究计算域的设置如下:Ahmed汽




图1 Ahmed汽车模型

Fig. 1 Ahmed car model

车到计算域入口的距离为 $3L$,车尾到计算域出口的距离为 $7L$,Ahmed汽车的两侧到计算域的两侧的距离为 $3W$,车顶到计算域的顶部为 $5H$ 。阻塞比 ε 为1.96%,其计算式^[5]为

$$\varepsilon = \frac{A_0}{A_I} \quad (1)$$

式中: ε 为风洞阻塞比; A_0 为车身正投影面积; A_I 为计算域的横截面积。

本研究使用ANSYS Fluent Meshing软件对计算域进行网格划分,四面体网格划分,边界层数为8,边界层增长率为1.1,第一次边界高度为1.121 7 mm,如图2所示。鉴于外流场的对称性,为了节省时间和计算资源,研究仅计算1/2计算域。

1.3 湍流模型和边界条件设置

本研究选择Realizable- ε 作为湍流模型和求解能力较好的SIMPLE^[6]算法。为满足研究目的和工程实践的要求,采用二阶迎风格式,设置迭代




图 2 计算域网格划分结果

Fig. 2 Computational domain meshing results

步数为 2 000 步。相较于标准 $k-\varepsilon$ 模型, 该模型能更好地捕捉边界层流动、气流分离以及二次流等复杂流动现象。入口 inlet 设置为速度入口, 来流速度 V_{inlet} 为 30 m/s, 压力出口 outlet 静压为 0 Pa, 计算域的各边界命名如图 3 所示。




图 3 计算域的边界

Fig. 3 Boundaries of computational domain

1.4 网格独立性验证

在保证模拟结果准确性的前提下, 最大限度地缩短模拟时间, 确定适宜的网格个数。本研究计算了 7 种不同网格尺寸的 Ahmed 汽车阻力系数。不同网格尺寸的阻力系数详见表 1。选择体网格数为 5 560 000 时的尺寸进行网格划分, 此时阻力系数的误差为 2.88%。

表 1 不同网格尺寸的阻力系数		
Table 1 Drag coefficients for different grid sizes		
体网格数/ 10^4	阻力系数 C_D	误差/%
165	0.324 7	13.92
202	0.323 7	13.58
307	0.315 4	10.67
397	0.308 2	8.14
528	0.307 6	7.93
556	0.293 2	2.88
796	0.293 2	2.88
实验值	0.285 0 ^[7]	—

2 选择设计变量和生成数据集

本研究以扩散器的 5 个几何尺寸作为设计变量, 示意图如图 4 所示。图中, X_1 为扩散器与水平面的夹角, X_2 为厚度, X_3 为长度, X_4 为过渡圆角半径, X_5 为两个扩散器的间距, 取值范围见表 2。




图 4 设计变量

Fig. 4 Design variables

表 2 设计变量取值范围	
Table 2 Range of values of design variables	
设计变量名	取值范围
扩散器与水平面的夹角 $X_1/(^\circ)$	[15°, 30°]
扩散器的厚度 X_2/mm	[5, 15]
扩散器的长度 X_3/mm	[100, 150]
扩散器的过渡圆角半径 X_4/mm	[10, 35]
两个扩散器的间距 X_5/mm	[10, 25]

研究中使用最优拉丁超立方 (OptLHD) 法对 5 个设计变量生成 40 组样本数据。利用三维建模软件对每组数据建模后, 使用 Fluent 软件对每组样本的阻力系数求解。数据集由这 40 组样本数据以及相应的仿真结果构成, 具体见表 3。

表 3 数据集						
Table 3 Datasets						
样本数	X_1	X_2	X_3	X_4	X_5	C_D
1	25.00	9.62	101.28	17.69	23.08	0.242 2
2	21.92	10.38	144.87	16.41	11.15	0.238 6
⋮	⋮	⋮	⋮	⋮	⋮	⋮
39	19.23	7.82	128.21	12.56	24.62	0.233 1
40	23.85	5.00	111.54	23.46	18.85	0.243 6

3 预测模型

3.1 径向基函数近似模型

径向基函数 (radial basis function, RBF) 近似模型是一种广泛应用于函数逼近、数据插值和机器学习领域的数学工具。其核心思想是利用径向基函数对输入数据进行加权求和, 从而构建一个逼近目标函数的模型。给定一组输入数据点 $\{x_i\}_{i=1}^N$ 及其对应的目标值 $\{y_i\}_{i=1}^N$, RBF 模型表示为

$$f(x) = \sum_{i=1}^N w_i \varphi(\|x - x_i\|) \quad (2)$$

式中: w_i 为权重; $\varphi(\|x - x_i\|)$ 为径向基函数; $\|x - x_i\|$ 为输入数据点与中心点 x_i 之间的欧氏距离。本研究选用常见的高斯函数作为径向基函数, 其具有平滑和快速衰减特性, 表达式^[8]为

$$\varphi(r) = \exp\left(-\frac{r^2}{2\sigma^2}\right) \quad (3)$$

式中: r 为距离; σ 为尺度参数。

3.2 极端随机树模型

极端随机树 (Extra Trees) 是一种集成学习方法, 是随机森林的一种变形^[9], 其融合了 Bagging 算法的思想和随机属性选择的概念。与常规决策树不同, Extra Trees 在每个节点不是寻找最优的划分属性, 而是随机选择属性进行划分, 这意味着它在划分节点时不考虑属性的重要性。与随机森林类似, Extra Trees 也使用自助采样方法创建训练数据的随机子集^[10], 每棵决策树都是在这些随机子集上训练的。对于给定的输入样本, 每棵决策树都会进行预测。在回归问题中, 所有决策树的预测结果取平均值作为最终预测。每棵基础决策树都会生长到最大深度或达到预设的停止条件。与普通决策树相比, Extra Trees 在生长过程中不会寻找最佳分割点, 而是随机选择特征子集进行划分。由于引入了更多的随机性, Extra Trees 计算成本通常低于普通决策树和随机森林, 尤其适合处理大型数据集。但这种随机性可能因选择不太相关的属性进行划分, 导致模型性能略有下降, 但其高效的计算能力和稳健性使其仍然是机器学习领域中的重要工具。

3.3 极限梯度提升模型

极限梯度提升 (extreme gradient boosting,

XGBoost) 模型是一种改进的梯度提升决策树 (GBDT) 算法, 由 Chen 等^[11] 提出。XGBoost 通过训练一系列基础分类器将它们组合成一个强分类器。在训练过程中, 首先使用初始训练集训练一个基础分类器, 然后根据其表现调整下一个基础分类器中训练样本的权重, 使分类错误的样本得到更多关注。通过多次迭代, 直到满足条件为止。最后, 对训练好的多个分类器进行加权和组合。与 GBDT 相比, XGBoost 具有准确率高、不易过度拟合、可扩展性强等特点。XGBoost 的目标函数是损失函数加上正则项。损失函数度量预测值与实际值之间的差异, 通过减少损失来优化目标函数; 正则项用于控制模型的复杂度, 防止出现过于极端的情况。

3.4 粒子群优化-反向传播混合算法

反向传播神经网络 (back propagation neural network, BPNN) 是解决多元回归问题 and 非线性特征建模的一种强有力的计算建模技术。神经网络的预测精度受神经网络结构的影响, 神经网络结构由输入层、隐含层和输出层组成^[12]。输入层接收输入变量的值, 并通过乘以权重 (w_i) 连接到隐藏层, 并将其分配给激活函数, 激活函数作为新的输入又传递给下一层的神经元, 表达式为

$$y_j^{(k)} = b_0 + \sum_{i=1}^n w_i x_i \quad (4)$$

$$y_{jout}^{(k)} = \frac{1}{1 + \exp(-y_j^{(k)})} \quad (5)$$

式中: k 为层数; j 为节点数; b_0 为阈值。

本研究的数据集按 7 : 1 : 2 的比例划分, 寄训练集占 70%、验证集占 10%、测试集占 20%。采用一种单隐含层 (5 个神经元)、5 个输入 ($X_1 \sim X_5$)、单输出 (C_D) 结构的神经网络。该预测模型的最大迭代步数为 1 000, 学习率为 0.01, 目标误差为 $1e-6$ 。粒子群优化 (particle swarm optimization, PSO) 是一种模拟自然界中动物群体行为的优化算法, 由 Eberhart 和 Kennedy 于 1995 年首次提出。该算法借鉴了鱼群游动和鸟群飞行等动物的集体行为, 利用这些行为模式来寻找最优解^[13]。PSO 算法是一种高效的优化策略, 其核心原理和操作机制都相对简洁明了。它无需依赖梯度信息, 并且所需的可调节参数数量非常有限。因其简单、易实现、并行处理能力强等特点, PSO 算法

在多种优化问题中得到了广泛应用。特别是在 BP 神经网络的权重和阈值优化方面, PSO 算法能够发挥出显著效果。PSO 算法优化 BP 神经网络的流程如图 5 所示。




图 5 PSO-BP 算法流程图

Fig. 5 Flowchart of PSO-BP algorithm

为比较不同预测模型的性能, 本研究采用决定系数 R^2 、均方根误差 RMSE 度量指标对模型的

预测能力进行评估。使用回归系数 R^2 和 RMSE 模型评价指标, 计算公式^[14] 分别为

$$R^2 = 1 - \sum_{i=1}^n \frac{(y_{i,Pre} - y_{i,CFD})^2}{y_{i,CFD}^2} \quad (6)$$

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (y_{i,Pre} - y_{i,CFD})^2}{n}} \quad (7)$$

式中: $y_{i,Pre}$ 为模型预测值; $y_{i,CFD}$ 为软件模拟值。

4 结果和分析

不同预测模型的拟合效果如图 6 所示。模型的回归曲线对比如图 7 所示。各模型回归曲线的决定系数和均方根误差对比见表 4。

Extra Trees 模型的参数配置见表 5。设计变量的重要性占比分别为: X_1 占比 86.10%, 对 C_D 影响最显著; X_2 、 X_3 、 X_4 占比分别为 3.70%、3.60%、3.60%, 对 C_D 影响效果其次; X_5 占比 3.10%, 对 C_D 影响效果最小。XGBoost 预测模型的参数设置见表 6。




图 6 不同预测模型的拟合效果对比

Fig. 6 Comparison of fitting effects of different prediction models




图 7 不同预测模型的回归曲线图对比

Fig. 7 Comparison of regression graphs of different prediction models

Table 4 Comparison of R^2 and RMSE of regression curve of fitted model		
模型	R^2	RMSE
RBF	0.960 7	0.001 7
Extra Trees	0.981 6	0.001 5
XGBoost	0.978 1	0.001 6
PSO-BP	0.993 3	0.000 9

Table 5 Extra Trees model parameter settings	
参数名	参数值
数据切分	0.7
节点分裂评价准则	MSE
内部节点分裂的最小样本数	2
叶子节点的最小样本数	1
叶子节点中样本的最小权重	0
树的最大深度	10
叶子节点的最大数量	50
决策树数量	100

Table 6 XGBoost model parameter settings	
参数名	参数值
数据切分	0.7
基学习器	gbtree
基学习器数量	100
学习率	0.1
L1正则项	0
L2正则项	1
样本征采样率	1
树特征采样率	1
节点特征采样率	1
叶子节点中样本的最小权重	0
树的最大深度	10

对比 4 种预测模型的拟合效果对比图可以看出, PSO-BP 预测模型预测结果和 CFD 值之间误差最小, RBF 近似模型预测结果和 CFD 值之间误差最大, 其中有多组数据的预测值和 CFD 值误差相对较大。4 种预测模型的回归曲线图中, 黑色直

线 $F=T$ 表示拟合度最高的情况, 即决定系数 $R^2=1$; 红色直线表示 CFD 值与预测值的拟合直线, 它越靠近黑色直线, 预测模型的精度就越高。对比回归曲线可以看出, PSO-BP 预测模型拟合精度最高, RMSE 最小; RBF 近似模型拟合精度最低, RMSE 最大; 上述预测模型的预测精度均满足工程要求, 决定系数 R^2 均大于 0.9。

5 结 语

采用 OptLHD 对 Ahmed 模型两侧安装的扩散器的 5 个特征尺寸进行设计, 一个包含 40 组样本数据的数据集就此产生, 将该数据集用于 RBF 近似模型, Extra Trees 预测模型, XGBoost 预测模型, PSO-BP 预测模型进行学习, 得出以下结论:

1) 汽车尾部安装扩散器可增加车辆的下压力, 从而提高车辆的高速稳定性和操作性能, 而安装在侧面可起到不错的减阻效果;

2) RBF 近似模型、Extra Trees、XGBoost、PSO-BP 等预测模型均可用于汽车阻力系数预测, 且预测精度满足要求;

3) 设计变量中对阻力系数影响最大的因素是扩散器与水平面的夹角 X_1 , 影响最小的是两个扩散器的间距 X_5 ;

4) PSO-BP 模型预测精度最高, RMSE 最小, RBF 近似模型拟合预测精度最低, RMSE 最大;

5) 将机器学习和传统方法结合, 是减少汽车空气动力学优化设计时间成本的有效方法之一。

参考文献:

- [1] ROSTAMZADEH-RENANI M, BAGHOOLIZADEH M, SAJADI S M, et al. A multi-objective and CFD based optimization of roof-flap geometry and position for simultaneous drag and lift reduction [J]. *Propulsion and Power Research*, 2024, 13(1): 26 – 45.
- [2] GUNPINAR E, COSKUN U C, OZSIPAH M, et al. A generative design and drag coefficient prediction system for Sedan car side silhouettes based on computational fluid dynamics [J]. *Computer-Aided Design*, 2019, 111: 65 – 79.
- [3] ANDRÉS-PÉREZ E, PAULETE-PERÍAÑEZ C. On the application of surrogate regression models for aerodynamic coefficient prediction [J]. *Complex & Intelligent Systems*, 2021, 7(4): 1991 – 2021.
- [4] 姜丰, 李卓, 汪怡平. 基于 GA-BP 神经网络的汽车空气阻力系数预测研究 [J]. *汽车工程学报*, 2023, 13(5): 730 – 738.
- [5] 侯卜瑛, 赵萌, 刘印桢, 等. 不同侧风角作用下 Ahmed 模型空气动力学特性分析 [J]. *科学技术与工程*, 2024, 24(2): 465 – 471.
- [6] 许建民, 龚晓岩, 郑庆杰, 等. 基于联接式通道的厢式货车减阻性能仿真研究 [J]. *汽车安全与节能学报*, 2023, 14(6): 774 – 782.
- [7] 张勇, 石佳琦, 谷正气, 等. 尾部特征参数对气动阻力交互影响与全局优化研究 [J]. *湖南大学学报(自然科学版)*, 2020, 47(2): 14 – 20.
- [8] JIANG Q H, ZHU L L, SHU C, et al. An efficient multilayer RBF neural network and its application to regression problems [J]. *Neural Computing and Applications*, 2022, 34(6): 4133 – 4150.
- [9] GAVEL A, ANDRAE R, FOUESNEAU M, et al. Estimating $[\alpha/\text{Fe}]$ from *Gaia* low-resolution BP/RP spectra using the ExtraTrees algorithm [J]. *Astronomy & Astrophysics*, 2021, 656: A93.
- [10] 李笑雪, 张思凝, 王娅娅, 等. 基于树型学习算法的短期流量预测研究 [J]. *电子测试*, 2021(19): 48 – 50.
- [11] CHEN T Q, CARLOS G. XGBoost: a scalable tree boosting system [C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. San Francisco: Association for Computing Machinery, 2016: 785 – 794.
- [12] PARK D, CHA J, KIM M, et al. Multi-objective optimization and comparison of surrogate models for separation performances of cyclone separator based on CFD, RSM, GMDH-neural network, back propagation-ANN and genetic algorithm [J]. *Engineering Applications of Computational Fluid Mechanics*, 2020, 14(1): 180 – 201.
- [13] 蔡改贫, 罗茜茜, 刘鑫. 基于 PSO-LSSVM 的 Ni-Cr-W-Mo 合金本构关系研究 [J]. *塑性工程学报*, 2020, 27(9): 140 – 146.
- [14] BAGHERI-ESFEH H, ROSTAMZADEH-RENANI M, ROSTAMZADEH-RENANI R, et al. Multi-objective optimization of drag and lift coefficients of a car integrated with canards [J]. *International Journal of Computational Fluid Dynamics*, 2020, 34(5): 346 – 362.

(编辑: 韩琳)